Tugas 2 Big Data Storage

SEN12TP: MongoDB + PostGIS vs HDFS-Parquet

Oct 10, 2026

Ringkasan

Mengambil **SEN12TP** (metadata citra satelit Sentinel-1 dan Sentinel-2) dengan **MongoDB + PostgreSQL/PostGIS** dan baseline **HDFS + Parquet**. Dataset ini tercantum di Lampiran Dataset dosen (entri "Sen12Landslides & SEN12TP"), jadi tidak perlu persetujuan dataset. Yang dipakai hanya berkas metadata `sen12tp-metadata.json` (1,3 MB). Berkas itu sudah diunduh, MD5-nya cocok dengan Zenodo, dan sudah diprofilkan pada 10 Okt 2026: 2.319 scene dari 1.236 area kajian. Citranya (± 222 GB tanpa kompresi) hanya dirujuk, tidak disimpan.

Judul usulan

Perbandingan MongoDB dan PostgreSQL/PostGIS terhadap Baseline HDFS-Parquet sebagai Penyimpanan Katalog Metadata Citra Satelit Sentinel-1/2 SEN12TP untuk Pencarian Spasial-Temporal Data Penginderaan Jauh

Judul ini memuat tiga hal yang diminta soal: pola dan teknologi (perbandingan MongoDB, PostgreSQL/PostGIS, dan baseline HDFS-Parquet), domain (metadata citra satelit penginderaan jauh), dan tujuan (pencarian spasial-temporal). Bila kolom Sheet terbatas, pakai versi pendek: *Evaluasi MongoDB dan PostgreSQL/PostGIS dengan Baseline HDFS-Parquet untuk Katalog Metadata Citra Satelit SEN12TP pada Pencarian Spasial-Temporal*.

Teks pendaftaran kombinasi di Sheet dosen: MongoDB (document store) + PostgreSQL/PostGIS (relasional spasial) | baseline HDFS+Parquet | Dataset: SEN12TP (sen12tp-metadata.json)

Alasan singkat

- **Ada di daftar dosen.** Entri lampiran itu memuat tautan Zenodo SEN12TP. Kita hanya memakai bagian SEN12TP; konfirmasi singkat ke dosen tetap disarankan.
- **Sudah dicek pada berkas asli.** Unduhan 1,3 MB cocok dengan MD5 di Zenodo. Profiling: GeoJSON, 2.319 scene unik, 9 atribut ditambah poligon, tanpa nilai kosong.
- **Masalah nyata dengan dua gaya penyimpanan yang bersaing.** Peneliti perlu menemukan scene menurut lokasi, bulan, dan tutupan lahan tanpa membuka ratusan GB citra. Standar katalog STAC lahir dari masalah serupa: tidak ada cara umum untuk mencari citra suatu tempat dari waktu ke waktu.
- **Tiga model data dalam satu cerita.** Dokumen GeoJSON (MongoDB), tabel relasional berindeks spasial (PostGIS), dan berkas kolumnar tanpa indeks spasial (Parquet). Perbandingannya jelas: indeks spasial lawan pindai.
- **Skala 100× dan 1.000× lewat simulasi.** 100× ≈ 232 ribu record dan 1.000× ≈ 2,3 juta record. Berkas mentah 1.000× hanya ± 1,3 GB (perkiraan), jadi muat di laptop.
- **Berbeda dari kelima contoh judul di soal;** yang terdekat MongoDB + Elasticsearch. Namun SEN12TP ada di daftar, jadi kelompok lain juga bisa memilihnya: cek Sheet sebelum mendaftar.

Kerjakan hari ini

- ☐ Cek Google Sheet dosen: pastikan belum ada kelompok lain yang mendaftarkan kombinasi yang sama, lalu daftarkan judul dan isian kolom E sampai H (Project Lead).
- ☐ Kirim pesan konfirmasi pemakaian berkas metadata ke dosen; drafnya ada di bagian "Draf pesan ke dosen" (Project Lead).
- ☐ Simpan `sen12tp-metadata.json` dan `profil.py` di folder bersama kelompok; semua anggota cek RAM dan ruang disk laptop (Data Collection Engineer dan semua anggota).

Cadangan: bila kombinasi ini ternyata sudah dipakai kelompok lain, dokumen sebelumnya (Open Food Facts + MongoDB + ClickHouse) masih berlaku, tetapi datasetnya di luar daftar dan perlu persetujuan dosen.

Pembagian tugas 5 orang

Tugas dibagi menurut enam peran di soal, dengan Project Lead dan Documentation/QA digabung ke Anggota 1 karena kelompok hanya lima orang. Ganti "Anggota 1–5" dengan nama kalian. Perkiraan jam di bawah adalah tebakan kasar saya (± 60 jam total, ± 12 jam per orang dalam 6 hari), bukan hasil pengukuran. Unduhan, cek MD5, dan profiling dataset sudah selesai pada 10 Okt 2026, jadi Anggota 2 langsung mulai dari generator skala.

Anggota	Peran	Luaran utama	Perkiraan jam
1	Project Lead + Documentation/QA	Isian Sheet bagian 1–2, diagram arsitektur final, slide pitching, hasil QA	12
2	Data Collection Engineer	Profil dataset dan skala, kamus data, generator S1/S10/S100/S1000, skrip konversi NDJSON, CSV, dan Parquet	12
3	Storage Engineer A (MongoDB)	Model data dan justifikasi MongoDB, rencana compose replica set, draf query	11
4	Storage Engineer B (PostgreSQL/PostGIS + baseline HDFS–Parquet)	Model data dan justifikasi PostGIS serta baseline, rencana compose, draf SQL	13
5	Performance Analyst	Rencana pengujian, hipotesis, template hasil, titik ukur di diagram, uji silang hasil spasial	10–12

Cocokkan peran dengan kekuatan masing-masing. Anggota 4 paling berat (PostGIS, Docker, Hadoop, dan Spark), jadi beri peran itu ke yang paling nyaman dengan Linux dan Docker. Bila Anggota 2 masih punya waktu lebih (datanya hanya 1,3 MB), serahkan draf Spark SQL baseline kepadanya.

Rincian tugas per anggota

Anggota 1 — Project Lead + Documentation/QA

- ☐ Hari 1: cek Sheet dosen (apakah kelompok lain memakai SEN12TP atau kombinasi serupa), daftarkan kombinasi, kirim pesan konfirmasi ke dosen.
- ☐ Isi bagian 1 (judul, identitas, peran) dan bagian 2 (latar belakang, kasus penggunaan) di Sheet.
- ☐ Gambar diagram arsitektur final di draw.io; diagram di dokumen ini hanya titik awal.
- ☐ QA lintas bagian: istilah, angka, dan nama kolom sama di Sheet, model data, dan rencana uji; cocokkan dengan rubrik.
- ☐ Susun slide pitching dan pimpin latihan.

Anggota 2 — Data Collection Engineer

- ☐ Unduh `sen12tp-metadata.json` (1,3 MB) dari Zenodo dan cek MD5 `ee86bf2caa4d8ec7d2bd67163a4396e7` (selesai 10 Okt 2026).
- ☐ Profiling dengan `profil.py`: jumlah scene, area unik, nilai kosong, sebaran split, bulan, tutupan lahan, iklim, serta rentang waktu dan lokasi (selesai 10 Okt 2026).
- ☐ Perluas profiling: ukuran poligon, selisih waktu S1–S2, dan cek apakah ada poligon yang melewati garis bujur ±180.
- ☐ Tulis generator skala S1/S10/S100/S1000 dengan seed tetap (sampel bersarang); simpan skripnya.
- ☐ Tulis skrip konversi: NDJSON untuk `mongoimport`, CSV dengan WKT untuk PostGIS, Parquet ZSTD dengan kolom bbox untuk HDFS.
- ☐ Buat kamus data untuk atribut inti dan catatan lisensi CC BY 4.0 beserta atribusinya.
- ☐ Tulis bagian "Profil dataset dan rencana skala" dan rapikan bagian "Link siap pakai".

Anggota 3 — Storage Engineer A (MongoDB)

- ☐ Rancang skema dokumen dan indeks MongoDB (2dsphere, `{landcover, month}`, `s2_time`, `spatial_id`); cocokkan nama dan tipe dengan hasil profiling Anggota 2.
- ☐ Pastikan geometri sah untuk indeks 2dsphere: GeoJSON, urutan bujur lalu lintang, cincin tertutup.
- ☐ Rancang ingest massal (`mongoimport` dari NDJSON) dan penambahan batch scene baru.
- ☐ Sketsa Docker Compose replica set 3 node untuk Tugas Tengah Semester.
- ☐ Tulis justifikasi MongoDB dan alternatif yang tidak dipilih (Elasticsearch/OpenSearch, Cassandra, Redis, Neo4j), terhubung ke CAP dan model data.
- ☐ Draf query MongoDB untuk beban kerja W1 sampai W6.

Anggota 4 — Storage Engineer B (PostgreSQL/PostGIS + baseline HDFS–Parquet)

- ☐ Rancang DDL PostGIS (`geometry(Polygon, 4326)`, indeks GiST dan btree) dan eksperimen dengan serta tanpa indeks spasial.

- ☐ Rancang layout HDFS dan Parquet (ZSTD, kolom bbox, partisi opsional) serta baseline Spark SQL.
- ☐ Sketsa Docker Compose: PostGIS (standby opsional), HDFS (NameNode dan 2 DataNode), Spark.
- ☐ Tulis justifikasi PostGIS dan baseline, plus alternatif yang tidak dipilih (TimescaleDB, Apache Sedona dan GeoParquet, Delta/Iceberg), terhubung ke row vs columnar.
- ☐ Draf SQL untuk beban kerja W2 sampai W6 dan W8.

Anggota 5 — Performance Analyst

- ☐ Susun rencana pengujian: beban kerja W1–W10, metrik, skala S1/S10/S100/S1000, minimal 3 kali ulang.
- ☐ Tulis hipotesis beserta kriteria terbukti atau tidaknya.
- ☐ Siapkan template tabel hasil dan anggaran sumber daya (RAM, disk, CPU per layanan).
- ☐ Tentukan titik pengukuran dan gambarkan di diagram (klien, `explain`, `EXPLAIN ANALYZE`, Spark UI).
- ☐ Rancang uji silang hasil spasial: jumlah scene yang sama dari ketiga penyimpanan, dan catat selisih MongoDB (bola) dengan PostGIS (planar).
- ☐ Periksa justifikasi Anggota 3 dan 4: apakah setiap klaimnya bisa diuji?

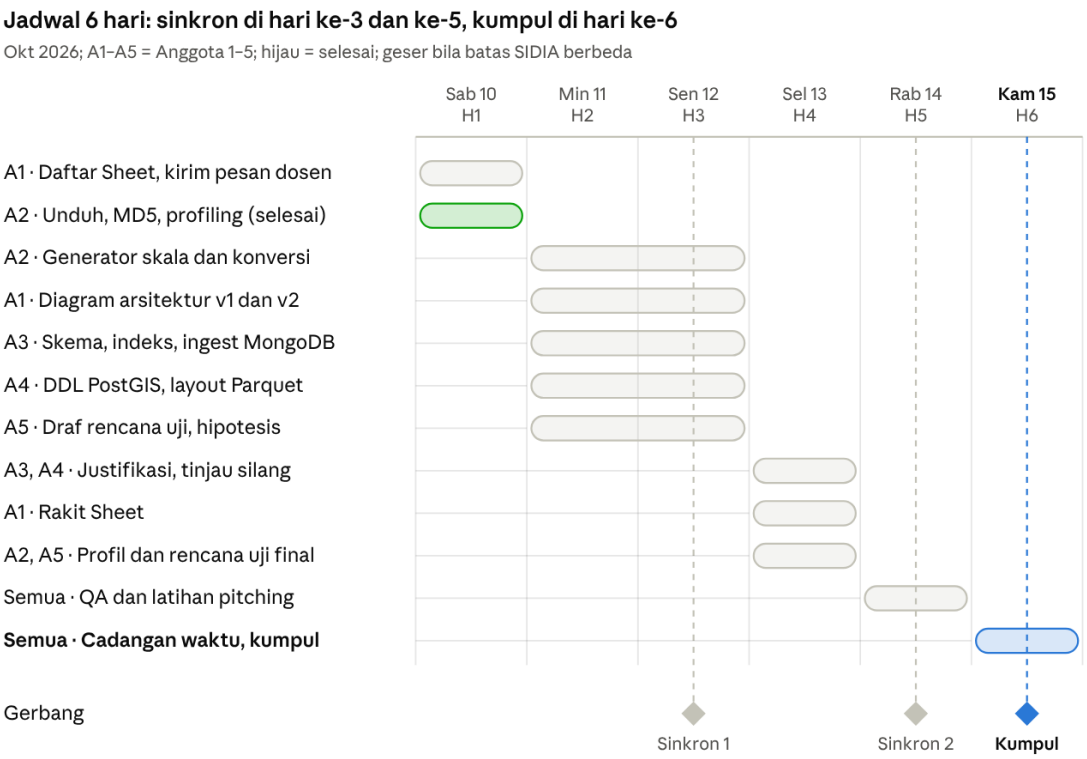
Peran yang sama berlanjut ke Tugas Tengah Semester: Docker Compose, memuat S1 sampai S1000, lalu menjalankan rencana uji.

Aturan kerja

- Dokumen ini untuk draf, Sheet dosen untuk isian final: ubah di satu tempat, lalu salin.
- Tinjau silang: Anggota 3 dan 4 saling memeriksa justifikasi; Anggota 2 dan 5 saling memeriksa profil dataset dan rencana uji; Anggota 1 menutup dengan QA.
- Dua sinkronisasi 30–45 menit: Hari 3 dan Hari 5.
- Satu penanggung jawab per bagian; bila dua anggota berbeda pendapat, Project Lead memutuskan.

Garis waktu 6 hari

Hari 1 = Sabtu 10 Okt 2026 (hari ini). Geser semuanya bila batas pengumpulan di SIDIA berbeda.



jadwal · 12 tugas, 3 gerbang

Batang menunjukkan hari kerja tiap tugas; batang hijau sudah selesai; belah ketupat menandai dua sinkronisasi dan hari kumpul.

Kerangka pitching

Enam slide mengikuti urutan komponen penilaian; pembicara boleh ditukar.

1. Masalah dan pengguna: peneliti yang mencari scene Sentinel tanpa membuka ratusan GB citra (Anggota 1)
2. Dataset dan skala 1×–1.000× (Anggota 2)
3. Arsitektur dan alur data (Anggota 3)
4. Mengapa MongoDB, PostGIS, dan baseline HDFS–Parquet (Anggota 3 untuk MongoDB, Anggota 4 untuk PostGIS dan baseline)
5. Rencana pengujian dan hipotesis (Anggota 5)
6. Hasil yang diharapkan dan rencana untuk Tugas Tengah Semester (Anggota 1)

Isian Google Sheet (siap salin)

Ada dua versi. Versi kolom Sheet (E sampai H) sudah dipadatkan untuk sel Sheet dosen. Versi lengkap tiga bagian mengikuti urutan isian di soal dan dipakai untuk laporan atau slide. Ganti isian dalam [kurung siku] sebelum dikirim.

Versi untuk kolom Sheet dosen (E sampai H)

Sheet dosen (dilihat dari tangkapan layar 9 Okt 2026, 12.41) memakai kolom B Kelompok, C Nama, D NIM, E Judul, F Sumber Data, G Deskripsi Singkat, dan H Justifikasi pemilihan teknologi; kolom peran tidak terlihat di tangkapan itu. Teks di bawah sudah dipadatkan untuk sel gabungan Kelompok 2.

Cara menempel: klik dua kali sel tujuan sampai kursor ada di dalam sel, baru tempel. Kalau langsung menempel pada sel yang hanya terpilih, teks berbaris-baris terpecah ke sel di bawahnya dan menimpa isi kelompok lain.

E · Judul

Perbandingan MongoDB dan PostgreSQL/PostGIS terhadap Baseline HDFS-Parquet sebagai Penyimpanan Katalog Metadata Citra Satelit Sentinel-1/2 SEN12TP untuk Pencarian Spasial-Temporal Data Penginderaan Jauh

F · Sumber Data

Sumber Data: SEN12TP - Sentinel-1 and -2 images, timely paired (Roßberg & Schmitt, 2023), Zenodo; yang dipakai hanya berkas metadata sen12tp-metadata.json (1,3 MB), bukan citranya (± 222 GB)

Format: JSON, semi-terstruktur (GeoJSON FeatureCollection, 2.319 scene dari 1.236 area kajian, Maret 2017 sampai Desember 2020); lisensi CC BY 4.0

Link: https://zenodo.org/records/7342060

G · Deskripsi Singkat

Proyek ini merancang katalog pencarian metadata citra satelit Sentinel-1 (radar) dan Sentinel-2 (optik) SEN12TP agar peneliti dapat menemukan scene yang tepat tanpa membuka ratusan GB citra, misalnya scene yang menutupi titik tertentu pada bulan Juli atau jumlah scene per tutupan lahan. Metadata 2.319 scene (geometri, ID, iklim, tutupan lahan, waktu pengambilan, kode EPSG) diperbesar lewat simulasi menjadi 100× (± 232 ribu record) dan 1.000× (± 2,3 juta record). MongoDB (document store, indeks 2dsphere) dan PostgreSQL/PostGIS (relasional, indeks spasial) melayani pencarian spasial-temporal dan lookup per ID, lalu keduanya dibandingkan dengan baseline HDFS-Parquet (Spark SQL) pada pencarian, agregasi, kecepatan ingest, dan ukuran penyimpanan.

Kalimat tambahan, opsional bila sel muat: Citra asli (± 222 GB) tidak disimpan di database; katalog hanya menyimpan metadata dan penunjuk ke citra di sumbernya (Zenodo).

H · Justifikasi pemilihan teknologi

Pencarian metadata citra satelit adalah pencarian spasial-temporal: poligon scene dicocokkan dengan titik atau area, lalu dibatasi bulan atau tutupan lahan. Karena itu dibandingkan dua penyimpanan berindeks spasial dari dua kategori berbeda (document store dan relasional), dengan HDFS-Parquet sebagai baseline tanpa indeks spasial.

(1) MongoDB (document store). Model data: satu scene = satu dokumen dengan geometri GeoJSON; `_id` = `scene_id`; skema fleksibel bila atribut scene bertambah. Indeks 2dsphere memakai geometri bola dan didukung oleh `$geoIntersects`. Row vs columnar: dokumen disimpan utuh, ideal untuk mengambil satu scene sekaligus, tetapi agregasi per tutupan lahan tetap membaca dokumen utuh. CAP: replica set dengan write concern majority dan baca dari primary condong ke CP; saat primary gagal, penulisan tertahan

sampai primary baru terpilih (dokumentasi MongoDB: median biasanya tidak lebih dari ± 12 detik pada konfigurasi default).

(2) PostgreSQL/PostGIS (relasional spasial). Model data: satu tabel `scenes` bertipe tegas dengan kolom `geom geometry(Polygon, 4326)` dan primary key `scene_id`. Indeks GiST menyimpan bounding box tiap geometri sebagai filter awal, lalu predikat seperti `ST_Intersects` memastikan kecocokan; `ST_Intersects` otomatis memakai indeks spasial yang tersedia (dokumentasi PostGIS). Row vs columnar: row store, satu scene dibaca utuh. CAP: satu primary dengan replikasi streaming ke standby; replikasi ini asinkron secara default, sehingga bila primary gagal, transaksi yang sudah commit bisa belum sampai ke standby (dokumentasi PostgreSQL), sedangkan replikasi sinkron membuat tiap commit menunggu konfirmasi standby. Menurut penilaian kami penulisan ke primary condong ke CP; perilaku persisnya diuji lewat promosi standby bila laptop memungkinkan.

(3) HDFS + Parquet (baseline). Berkas kolumnar immutable (ZSTD) dengan skema tertanam di berkas, dikueri dengan Spark SQL. Tanpa indeks spasial: mencari scene yang menutupi satu titik berarti memindai berkas dengan pra-filter bounding box. HDFS memakai model tulis-sekali-baca-banyak; NameNode mengelola metadata dan umumnya dipandang mengutamakan konsistensi, sedangkan blok direplikasi antar DataNode. Perannya: tolok ukur seberapa besar keunggulan indeks spasial MongoDB dan PostGIS.

Alternatif yang dipertimbangkan tetapi tidak dipilih: Elasticsearch/OpenSearch (mesin pencari, opsional sebagai ekstensi), Cassandra (satu tabel per pola kueri, kueri spasial bukan kekuatannya), Redis (cache untuk lookup ID; perintah GEO bekerja pada titik, bukan poligon), Neo4j (bukan beban kerja graf), TimescaleDB (data bukan deret waktu), Apache Sedona dan GeoParquet serta Delta Lake/Iceberg (peningkatan atas baseline; soal meminta HDFS + Parquet polos, dicatat sebagai pengembangan lanjutan), dan object storage seperti MinIO (tempat yang tepat untuk citra, tetapi citra bukan data tabular atau semi-terstruktur).

Semua klaim kinerja adalah hipotesis desain yang akan diuji pada Tugas Tengah Semester.

Pemakaian hanya berkas metadata dari entri "Sen12Landslides & SEN12TP" di lampiran dosen masih menunggu konfirmasi (lihat bagian "Draf pesan ke dosen").

Versi lengkap tiga bagian

Urutannya mengikuti isian di soal. Bagian 1 dan 2 untuk Sheet bila dosen meminta isian yang lebih rinci; bagian 3 adalah bentuk panjang dari kolom H.

1. Judul, identitas kelompok, dan peran

Judul: Perbandingan MongoDB dan PostgreSQL/PostGIS terhadap Baseline HDFS-Parquet sebagai Penyimpanan Katalog Metadata Citra Satelit Sentinel-1/2 SEN12TP untuk Pencarian Spasial-Temporal Data Penginderaan Jauh

Kelompok: KELOMPOK 2, kelas [kelas]

Anggota (menurut Sheet dosen): Elsa Claudia Putri (23051204038), Muhammad Syah Levi (23051204051), Muhammad Wildan Arif Maulana (23051204065), Marsanda Sofi Aminarti (23051204066), Maulana Hidayah Syaif Ali Khan (23051204068).

Peran	Nama dan NIM

Peran	Nama dan NIM
Project Lead + Documentation/QA	[nama, NIM]
Data Collection Engineer	[nama, NIM]
Storage Engineer A (MongoDB)	[nama, NIM]
Storage Engineer B (PostgreSQL/PostGIS + baseline HDFS–Parquet)	[nama, NIM]
Performance Analyst	[nama, NIM]

Dengan lima anggota, peran Project Lead dan Documentation/QA dirangkap satu orang. Pasangkan nama dengan peran setelah kelompok sepakat.

2. Latar belakang dan kasus penggunaan

Masalah. Misi Sentinel-1 (radar) dan Sentinel-2 (optik) menghasilkan citra yang ukurannya ratusan GB. Dataset SEN12TP, misalnya, berisi 2.319 scene berpasangan waktu dari 1.236 area kajian (tiap scene 20 km × 20 km pada resolusi 10 m, selisih waktu radar dan optik paling lama 12 jam) dengan ukuran 222 GB tanpa kompresi. Peneliti yang melatih atau menguji model biasanya hanya butuh sebagian scene: yang menutupi lokasi tertentu, pada bulan tertentu, atau dengan tutupan lahan tertentu. Tanpa katalog, mereka harus mengunduh dan membuka citra hanya untuk mencari. Katalog metadata (geometri scene, ID, iklim, tutupan lahan, waktu pengambilan, kode EPSG) menjawab pertanyaan "scene mana" dalam hitungan milidetik, dan citra baru diambil dari sumbernya untuk scene yang terpilih.

Pengguna. Peneliti penginderaan jauh dan pemodel machine learning yang memilih data latih dan uji; data engineer yang menjaga katalog saat scene baru ditambahkan; aplikasi atau notebook yang mengambil metadata satu scene menurut ID.

Kebutuhan penyimpanan.

- Real-time (operasional): ambil satu scene menurut `scene_id` dengan latensi rendah dan banyak klien bersamaan.
- Pencarian: scene yang menutupi titik atau beririsan dengan area, dibatasi bulan, tutupan lahan, atau iklim (spasial-temporal).
- Analitik: jumlah scene per tutupan lahan, per iklim, per bulan, dan per pembagian train/test.
- Pembaruan: menambah batch scene baru tanpa memuat ulang seluruh katalog.
- Historis: salinan batch terkompresi untuk analisis ulang (baseline HDFS + Parquet).

Dataset. SEN12TP – Sentinel-1 and -2 images, timely paired (Roßberg & Schmitt, 2023; lisensi CC BY 4.0). Yang dipakai hanya `sen12tp-metadata.json` (1,3 MB): GeoJSON FeatureCollection berisi 2.319 scene, masing-masing dengan 9 atribut dan satu poligon. Skala 1× = 2.319 scene, dibesarkan lewat simulasi menjadi 100× (± 232 ribu record) dan 1.000× (± 2,3 juta record). Citra (222 GB tanpa kompresi) hanya dirujuk, tidak disimpan.

Tujuan. Membandingkan MongoDB, PostgreSQL/PostGIS, dan baseline HDFS + Parquet pada waktu muat, latensi kueri (lookup, spasial, spasial-temporal, agregasi), ukuran penyimpanan, perilaku saat skala naik dari 1× ke 1.000×, dan ketahanan saat satu node gagal.

3. Justifikasi pemilihan teknologi

Kasus ini punya satu pertanyaan utama, yaitu pencarian spasial-temporal, yang bisa dijawab oleh tiga gaya penyimpanan. Karena itu rancangannya berupa perbandingan: MongoDB dan PostgreSQL/PostGIS sama-sama berindeks spasial tetapi berbeda model data, sedangkan HDFS + Parquet menjadi baseline tanpa indeks spasial. Data yang sama dimuat ke ketiganya, lalu kueri yang sama dijalankan.

MongoDB (document store): lookup per ID, pencarian spasial, penambahan scene

- **Model data:** satu scene = satu dokumen BSON dengan geometri GeoJSON; `_id` diisi `scene_id`, jadi lookup memakai primary key. Skema fleksibel menyerap atribut tambahan tanpa migrasi tabel.
- **Indeks spasial:** indeks `2dsphere` mendukung kueri pada permukaan bola, dan `$geoIntersects` memakai geometri bola. Koordinat harus berurutan bujur lalu lintang.
- **Row vs columnar:** dokumen disimpan utuh, sehingga satu pembacaan mengambil seluruh metadata scene. Untuk agregasi satu-dua atribut (misalnya jumlah per tutupan lahan) ia tetap membaca dokumen utuh.
- **CAP:** replica set punya satu primary. Dengan write concern `majority` dan baca dari primary, MongoDB condong ke konsistensi (CP). Saat primary gagal, penulisan tertahan sampai primary baru terpilih; dokumentasi MongoDB menyebut median waktunya biasanya tidak lebih dari ± 12 detik pada konfigurasi default. Pembacaan dari secondary bisa tertinggal karena replikasi asinkron.
- **Batas dokumen:** satu dokumen maksimal 16 MiB, sedangkan satu scene citra ± 96 MB (perkiraan: 222 GB dibagi 2.319 scene). Untuk berkas sebesar itu MongoDB menyediakan GridFS. Ini salah satu alasan citra tidak disimpan di MongoDB.

PostgreSQL/PostGIS (relasional spasial): pencarian spasial dengan filter atribut, agregasi SQL

- **Model data:** satu tabel `scenes` bertipe tegas; geometri di kolom `geom geometry(Polygon, 4326)`; kunci utama `scene_id`. Skema tegas cocok karena profiling menemukan satu susunan properti dan tidak ada nilai kosong.
- **Indeks spasial:** indeks GiST menyimpan bounding box tiap geometri sebagai filter awal, lalu predikat seperti `ST_Intersects` memastikan kecocokan; `ST_Intersects` otomatis memakai indeks spasial yang tersedia. Tipe `geometry` bersifat planar (derajat dianggap bidang datar), berbeda dengan 2dsphere MongoDB yang bola, sehingga hasil di dekat tepi poligon bisa berbeda tipis dan perlu diuji silang.
- **Row vs columnar:** row store; satu scene dibaca utuh lewat primary key, dan agregasi SQL (`GROUP BY`) membaca baris utuh dari heap.
- **CAP:** satu primary dengan replikasi streaming ke standby. Dokumentasi PostgreSQL menyebut replikasi streaming asinkron secara default: bila primary gagal, transaksi yang sudah commit bisa belum sampai ke standby, dan jumlah data yang hilang sebanding dengan jeda replikasi saat failover. Replikasi sinkron membuat tiap commit menunggu konfirmasi standby. Menurut penilaian kami penulisan ke primary condong ke konsistensi (CP); perilaku persisnya kami uji lewat promosi standby (`pg_ctl promote` atau `pg_promote()`), bila laptop memungkinkan.

HDFS + Parquet (baseline): arsip batch dan pembanding tanpa indeks spasial

- **Model data:** berkas Parquet kolumnar dengan skema tertanam di berkas; atribut datar yang sama, geometri sebagai WKT atau WKB, ditambah kolom bbox (`min_lon`, `max_lon`, `min_lat`, `max_lat`). Spark SQL dipakai untuk kueri.

- **Row vs columnar:** data disimpan per kolom (kompresi ZSTD, pemangkasan kolom), sehingga agregasi satu-dua kolom hemat I/O. Tidak ada indeks spasial maupun point-lookup: mencari scene untuk satu titik berarti memindai dengan pra-filter bbox, dan mengambil satu `scene_id` pun berarti memindai.
- **CAP dan ketahanan:** HDFS memakai model tulis-sekali-baca-banyak; NameNode menyimpan metadata dan umumnya dipandang mengutamakan konsistensi, dan blok direplikasi antar DataNode, jadi data tetap terbaca saat satu DataNode mati. Berkas bersifat immutable, sehingga penambahan scene berarti menulis berkas baru.
- **Peran baseline:** menjawab seberapa besar keunggulan indeks spasial MongoDB dan PostGIS dibanding sekadar file kolumnar di HDFS.

Alternatif yang dipertimbangkan, namun tidak dipilih

Alternatif	Alasan tidak dipilih
Elasticsearch / OpenSearch	Mesin pencari yang juga mendukung kueri geospasial dan agregasi, tetapi kami membandingkan penyimpanan utama, dan katalog ini tidak butuh pencarian teks berperingkat. Dicatat sebagai ekstensi opsional.
Cassandra	Wide-column dengan tulis berat dan skala linear (AP), tetapi tiap pola kueri butuh tabel sendiri dan kueri spasial bukan kekuatannya. Kebutuhan kami adalah filter spasial dan atribut yang fleksibel.
Redis	Cocok sebagai cache di depan lookup `scene_id`. Perintah GEO bekerja pada titik, bukan poligon scene, dan data harus muat di memori. Opsional sebagai cache, bukan penyimpanan utama.
Neo4j	Graf berguna untuk relasi, tetapi beban kerja utama kami bukan penelusuran relasi antar scene.
TimescaleDB	Dirancang untuk deret waktu. Metadata scene bukan aliran sensor; tiap scene hanya punya dua cap waktu (Sentinel-1 dan Sentinel-2).
Apache Sedona / GeoParquet	Menambah fungsi spasial pada Spark dan geometri pada Parquet, jadi peningkatan alami untuk baseline. Soal meminta HDFS + Parquet polos sebagai pembanding; kami catat sebagai pengembangan lanjutan.
Delta Lake / Iceberg	Menambah transaksi ACID dan upsert di atas Parquet. Peningkatan atas baseline, tetapi soal meminta HDFS + Parquet polos; dicatat sebagai pengembangan lanjutan.
Object storage (MinIO, S3) untuk citra	Tempat yang tepat untuk citra mentah (222 GB), tetapi citra bukan data tabular atau semi-

Alternatif	Alasan tidak dipilih
	terstruktur sehingga di luar syarat dataset. Katalog hanya menyimpan penunjuk ke citra.
STAC (standar katalog)	Standar format metadata dan API untuk katalog citra, bukan mesin penyimpanan. Data sumber sudah berbentuk GeoJSON, jadi pemetaan ke Item STAC bisa menjadi pengembangan lanjutan.

Semua klaim kinerja di atas adalah hipotesis desain. Pembuktiannya lewat rencana pengujian pada Tugas Tengah Semester.

Mengapa opsi ini

Menurut penilaian saya, SEN12TP versi metadata unggul pada persetujuan, kesesuaian dengan syarat dataset, dan ringannya beban laptop. Kelemahannya dua: datanya kecil sehingga skala 100× dan 1.000× adalah hasil simulasi, dan atributnya datar. Dokumen Open Food Facts sebelumnya ikut dibandingkan sebagai cadangan.

Kriteria	Usulan: SEN12TP metadata + MongoDB + PostGIS	Cadangan: Open Food Facts + MongoDB + ClickHouse
Akses data dan lisensi	**Kuat**: satu berkas 1,3 MB, MD5 sudah dicek, CC BY 4.0	**Kuat**: unduhan langsung (Parquet 7,86 GB, JSONL, CSV), lisensi ODbL
Persetujuan dosen	**Kuat**: tercantum di lampiran (entri "Sen12Landslides & SEN12TP")	**Lemah**: di luar daftar, wajib disetujui dosen
Kesesuaian format (tabular atau semi-terstruktur, minimal 5 atribut)	**Kuat**: GeoJSON, 9 atribut ditambah poligon, tanpa nilai kosong	**Kuat**: Parquet, ± 110 kolom, sebagian bersarang
Variasi beban kerja	**Sedang**: lookup ID, titik-dalam-poligon, spasial-temporal, agregasi, tambah batch; tanpa pencarian teks	**Kuat**: lookup, filter, agregasi, pencarian teks, upsert harian
Kekayaan model data	**Sedang**: 9 atribut datar dan satu poligon; seragam, tanpa nilai kosong	**Kuat**: ± 110 kolom, bersarang, banyak nilai kosong
Kelayakan skala 100×	**Sedang**: 1× hanya 2.319 baris; 100× (± 232 ribu) dan 1.000× (± 2,3 juta) berasal dari simulasi	**Kuat**: sampling data nyata dari 4,76 juta produk
Beban untuk laptop kelompok	**Kuat**: 1.000× hanya ± 1,3 GB berkas mentah (perkiraan); yang berat HDFS dan Spark	**Sedang**: sampel 100× (± 900 ribu produk) muat, tetapi tiga penyimpanan sekaligus butuh

Kriteria	Usulan: SEN12TP metadata + MongoDB + PostGIS	Cadangan: Open Food Facts + MongoDB + ClickHouse
		RAM dan disk lega
Keunikan antarkelompok	**Sedang** (perkiraan): ada di daftar, jadi kelompok lain bisa memilihnya; pasangan MongoDB + PostGIS untuk katalog spasial-temporal tidak ada di lima contoh soal	**Kuat** (perkiraan): bukan tema longsor, pasangan teknologi berbeda dari lima contoh
Cerita pitching	**Kuat**: dari ratusan GB citra ke jawaban "scene mana" dalam milidetik	**Kuat**: scan barcode di rak, lalu pertanyaan gizi tingkat nasional

Keduanya memakai baseline HDFS + Parquet. Pilih SEN12TP bila ingin tanpa persetujuan tambahan dan beban laptop ringan; pilih Open Food Facts bila ingin data yang lebih kaya dan siap menunggu persetujuan dosen.

Penilaian Kuat, Sedang, dan Lemah adalah penilaian saya, bukan data. Fakta SEN12TP saya cek pada 10 Okt 2026 dari halaman Zenodo dan hasil profiling berkas. Sumber: SEN12TP di Zenodo, Open Food Facts, STAC.

Mengapa bukan citranya

Citra (± 222 GB tanpa kompresi, 237,9 GB berkas zip di Zenodo) tidak dipakai sebagai dataset karena empat hal.

Alasan	Rincian
Bentuk data	Citra raster, bukan data tabular atau semi-terstruktur seperti syarat soal
Skala 100×	222 GB × 100 ≈ 22 TB; tidak mungkin di laptop kelompok
Ukuran satu scene	± 96 MB (perkiraan: 222 GB dibagi 2.319 scene), sedangkan batas satu dokumen MongoDB 16 MiB
Tempat yang tepat	Object storage seperti MinIO atau S3; katalog cukup menyimpan metadata dan penunjuk ke citra di Zenodo

Batas 16 MiB berasal dari halaman Limits di dokumentasi MongoDB, yang juga menyebut GridFS untuk berkas lebih besar: MongoDB Limits.

Perubahan dari usulan awal

Usulan awal dari teman kelompok sudah tepat memilih metadata dan pencarian spasial-temporal. Empat perubahan di bawah memperkuat rancangan terhadap syarat soal.

Aspek	Usulan awal	Versi di dokumen ini	Alasan
Teknologi	Apache Parquet pada HDFS (baseline) dan MongoDB	MongoDB dan PostgreSQL/PostGIS, dengan HDFS + Parquet sebagai baseline	Soal meminta minimal 2 teknologi dari kategori berbeda ditambah baseline. PostGIS memberi pembanding berindeks spasial dari kategori relasional.
Judul	"Perbandingan Apache Parquet pada HDFS (Baseline) dan MongoDB ..."	"Perbandingan MongoDB dan PostgreSQL/PostGIS terhadap Baseline HDFS-Parquet ..."	Baseline berperan sebagai pembanding, jadi dua penyimpanan utama muncul lebih dulu.
Skala	100× (± 232 ribu record, ± 126 MB)	100× dan 1.000× (± 2,3 juta record, ± 1,3 GB)	Pada 100× datanya masih kecil, sehingga selisih indeks sulit terlihat. 1.000× memberi kurva skala yang lebih jelas.
Pemeriksaan berkas	Pemeriksaan CRS dan struktur tidak disebut	Sudah diperiksa pada berkas asli: CRS84 (bujur–lintang), 9 atribut, tanpa nilai kosong	Menghindari kejutan saat membangun indeks spasial.

Risiko dan perbaikannya

Risiko	Dampak	Perbaikan
Data asli hanya 2.319 baris; 100× dan 1.000× hasil simulasi	Hasil bisa dinilai kurang meyakinkan	Skala sampai 1.000×; jelaskan aturan simulasi di bagian profil dan akui bahwa data simulasi tidak mempertahankan hubungan geografis antar atribut.
Overhead Spark mendominasi pada skala kecil	Baseline tampak lambat secara tidak adil	Ukur di sesi yang sudah hangat; sebagai pembanding tambahan, baca Parquet yang sama dengan mesin kueri berkas lain (misalnya DuckDB) agar efek layout terpisah dari overhead Spark.
MongoDB (bola) dan PostGIS	Jumlah hasil antar penyimpanan	Uji silang jumlah hasil W2

Risiko	Dampak	Perbaikan
`geometry` (planar) bisa berbeda di tepi poligon	tidak persis sama	sampai W4 dan catat selisihnya; opsional bandingkan dengan tipe `geography` di PostGIS.
Kelompok lain juga memilih SEN12TP	Kombinasi tidak unik	Cek Sheet hari ini; pertahankan fokus katalog spasial-temporal dan pasangan MongoDB + PostGIS di judul.
Dosen mempertanyakan pemakaian metadata saja	Dianggap bukan dataset yang utuh	Kirim pesan konfirmasi; argumennya, metadata berformat GeoJSON semi-terstruktur sesuai syarat, sedangkan citra raster tidak.
Atribut datar, jadi perbandingan row vs columnar kurang kaya	Justifikasi kurang tajam	Tambahkan kolom turunan (bbox) dan jalankan agregasi W5 dan W6 untuk menunjukkan beda pemangkasan kolom; akui keterbatasannya di laporan.
RAM laptop terbatas (laptop Wildan 12 GB, ± 1,7 GB kosong saat dicek)	Tiga penyimpanan sekaligus tidak muat	Jalankan satu penyimpanan sekali waktu dan batasi memori tiap container; HDFS dan Spark yang paling berat.

Pemetaan ke rubrik penilaian

Komponen	Bobot	Dipenuhi di	Pemilik
Kejelasan judul dan kasus penggunaan	15%	Ringkasan; Isian Sheet (kolom E sampai H dan bagian 1–2)	Anggota 1
Kesesuaian dan profil dataset	15%	Profil dataset dan rencana skala	Anggota 2
Rancangan arsitektur dan diagram	25%	Arsitektur dan diagram	Anggota 1 (gambar), Anggota 3–5 (isi)
Justifikasi pemilihan teknologi	20%	Isian Sheet (kolom H dan bagian 3)	Anggota 3 dan 4
Draf model data dan rencana pengujian	15%	Draf model data; Rencana pengujian	Anggota 3–4 (model), Anggota 5 (uji)
Presentasi pitching	10%	Kerangka pitching di Pembagian tugas	Semua; Anggota 1 memimpin

Profil dataset dan rencana skala

SEN12TP versi metadata memenuhi ketiga syarat soal: semi-terstruktur (GeoJSON), 9 atribut ditambah geometri (syarat minimal 5), dan bisa dibesarkan minimal 100× lewat simulasi. Angka di bawah berasal dari profiling berkas asli pada 10 Okt 2026 dengan `profil.py`, kecuali yang diberi tanda "perkiraan" atau "menurut Zenodo".

Profil ringkas

Aspek	Nilai
Sumber	SEN12TP - Sentinel-1 and -2 images, timely paired, Zenodo, versi 1
Penulis dan terbit	Thomas Roßberg dan Michael Schmitt, University of the Bundeswehr Munich; terbit 29 Mar 2023 (diubah 20 Apr 2023)
DOI dan makalah	DOI 10.5281/zenodo.7342060. Makalah terkait menurut Zenodo: "A globally applicable method for NDVI estimation from Sentinel-1 SAR backscatter using a deep neural network and the SEN12TP dataset", PFG 2023 (doi 10.1007/s41064-023-00238-y)
Lisensi	CC BY 4.0; atribusi wajib
Berkas yang dipakai	`sen12tp-metadata.json`, 1,3 MB (1.235 KiB), MD5 `ee86bf2caa4d8ec7d2bd67163a4396e7`, cocok dengan MD5 di Zenodo
Berkas yang tidak dipakai	Citra: `sen12tp-v1-test.zip` 23,0 GB dan lima bagian latih (53,2; 54,3; 36,7; 33,3; 37,3 GB), total 237,9 GB; 222 GB tanpa kompresi menurut Zenodo
Bentuk data	GeoJSON FeatureCollection, CRS84 (bujur–lintang WGS 84); 2.319 Feature, semuanya Polygon (cincin tertutup 5 titik)
Jumlah scene dan area	2.319 scene dengan 2.319 `scene_id` unik; 1.236 area kajian unik (`spatial_id`)
Kualitas	Satu susunan properti; 0 nilai kosong
Rentang waktu	Maret 2017 sampai Desember 2020 (cap waktu S2 pertama 2017-03-28 dan terakhir 2020-12-30, UTC)
Rentang lokasi	Bujur −172,95 sampai 178,24; lintang −51,32 sampai 77,84
Ukuran dan selisih waktu	Tiap scene 20 km × 20 km pada piksel 10 m; selisih waktu radar dan optik paling lama 12 jam,

Aspek	Nilai
	hampir semuanya sekitar 6 jam (menurut Zenodo)

Sebaran nilai (hasil profiling)

- split: train 2.095, test 224.
- month: 175 sampai 205 scene per bulan, hampir seragam.
- landcover (8 kelas): Cropland 329, Grassland 322, Forest 312, Built up 309, Shrubs 300, Wetlands 291, Bare/Moss/Lichen 289, Ice/Snow 167.
- climate (14 kelas): Cs 192, BS 187, Cf 185, BW 183, Df(a|b) 182, Cw 180, Ds 180, Df(c|d) 174, Dw 172, Am 168, Aw 166, Af 164, ET 151, EF 35.

Kelas yang jarang (EF 35 scene, Ice/Snow 167 scene) cocok sebagai filter yang sangat selektif, dan kelas yang umum (Cropland 329 scene) sebagai filter longgar, jadi keduanya dipakai di W4. Kode iklim ini tampaknya mengikuti klasifikasi Köppen–Geiger; cek ke makalah sebelum ditulis di laporan.

Rencana skala 1× sampai 1.000×

Skala	Isi	Perkiraan record	Perkiraan berkas mentah	Fungsi
1× (S1)	Seluruh 2.319 scene asli	2.319	1,3 MB	Uji fungsional dan kalibrasi
10× (S10)	S1 + record simulasi	± 23 ribu	± 12,6 MB	Titik tengah kurva skala
100× (S100)	S10 + record simulasi	± 232 ribu	± 126 MB	Syarat soal (minimal 100×)
1.000× (S1000)	S100 + record simulasi	± 2,3 juta	± 1,3 GB	Skala uji utama

- Ukuran berkas mentah = jumlah record × ± 545 byte per feature (1.235 KiB dibagi 2.319). Ini perkiraan; ukuran di Parquet dan di database diukur setelah muat (W7).
- Sampel dibuat bersarang (S1 ⊂ S10 ⊂ S100 ⊂ S1000) dengan seed tetap, supaya hasil antar skala bisa dibandingkan dan diulang.
- S1 adalah data asli utuh. Record tambahan mengambil climate, landcover, month, dan split dari sebaran data asli, sedangkan poligonnya adalah salinan poligon asli yang digeser seluruhnya (bentuk tetap) dengan offset acak.
- Posisi hasil geseran dijaga di dalam sekitar ±179° bujur dan ±85° lintang agar tidak melewati garis ±180°. Pada data asli tidak ada poligon yang melewati garis itu (disimpulkan dari nilai ekstrem bujur −172,95 dan 178,24).
- Cap waktu S2 dibangkitkan sesuai month dalam rentang Maret 2017 sampai Desember 2020, dan selisih S1–S2 diambil dari sebaran selisih pada data asli (paling lama 12 jam).
- scene_id baru berurutan, spatial_id mengikuti area asal. Usulan: tambahkan kolom sim_batch (0 = data asli) supaya record simulasi mudah dikenali.

- Keterbatasan: data simulasi tidak mempertahankan hubungan geografis antara tutupan lahan atau iklim dan lokasi (poligon Ice/Snow bisa jatuh di mana saja). Cukup untuk menguji kinerja penyimpanan, tidak untuk analisis ilmiah.

Atribut inti (kamus data awal)

Nama atribut mengikuti berkas; cocokkan ulang bila versi berkas berubah.

Atribut	Tipe	Contoh dari berkas	Dipakai untuk
scene_id	integer	1868	Kunci utama dan lookup (W1)
spatial_id	integer	720	Mengelompokkan scene per area kajian (1.236 nilai unik)
split	teks	train	Filter dan agregasi (W5)
climate	teks, 14 kelas	Cs - Temperate, dry summer	Filter dan agregasi (W5, W6)
landcover	teks, 8 kelas	Ice/Snow	Filter gabungan spasial dan atribut (W4), agregasi (W5)
s1_timestamp_ms	integer, milidetik epoch	1577489275000 (2019-12-27 23:27:55 UTC)	Waktu Sentinel-1; diubah menjadi s1_time
s2_timestamp_ms	integer, milidetik epoch	1577457752727 (2019-12-27 14:42:32 UTC)	Waktu Sentinel-2; diubah menjadi s2_time (W3, indeks waktu)
utm_epsg	teks	EPSG:32719	Zona UTM scene; disimpan sebagai atribut
month	integer 1–12	12	Filter bulan (W3) dan agregasi (W6)
geometri	Polygon bujur–lintang	5 titik, cincin tertutup (scene 1868: sekitar bujur −70,3 dan lintang −34,6)	Indeks spasial (W2–W4) dan kolom bbox untuk Parquet

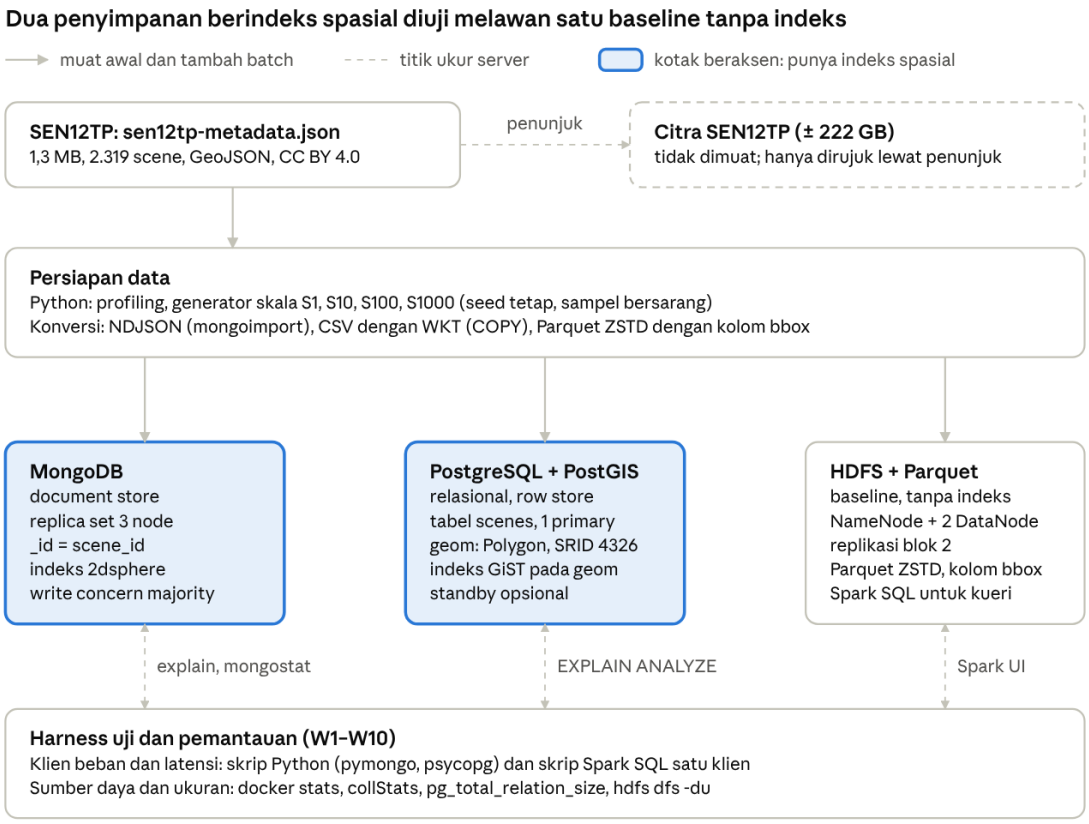
Catatan penggunaan

- Satu sumber untuk tiga penyimpanan: semuanya berangkat dari sen12tp-metadata.json yang sama dan generator yang sama, sehingga selisih kinerja bukan karena perbedaan data.
- Hanya metadata: citra tidak diunduh dan tidak dimasukkan ke database. Katalog menyimpan metadata dan penunjuk ke Zenodo (lihat "Mengapa bukan citranya").

- Atribusi: cantumkan "SEN12TP - Sentinel-1 and -2 images, timely paired. Roßberg & Schmitt (2023). Zenodo. https://doi.org/10.5281/zenodo.7342060. Lisensi CC BY 4.0." di laporan dan slide, dan cek format sitasi yang diminta di halaman Zenodo.
- Entri lampiran dosen berbunyi "Sen12Landslides & SEN12TP". Kelompok memakai bagian SEN12TP saja; Sen12Landslides tidak dipakai.
- Perangkat umum: untuk S1000 dengan semua layanan sekaligus, siapkan ± 16 GB RAM dan ± 30 GB disk kosong, sebagian besar untuk image Docker (perkiraan saya, belum diukur).
- Laptop Wildan (sudah dicek): RAM 12 GB (saat dicek hanya ± 1,7 GB kosong), prosesor Intel Skylake 2,3 GHz (kemungkinan dual-core), disk belum dicek. Datanya ringan; yang berat HDFS dan Spark. Jalankan satu penyimpanan sekali waktu, batasi memori tiap container, dan jalankan pengujian yang dibandingkan di satu mesin yang sama.

Arsitektur dan diagram

Satu sumber metadata (SEN12TP) diperbesar oleh generator, lalu dimuat ke tiga penyimpanan: MongoDB dan PostgreSQL/PostGIS dengan indeks spasial, serta HDFS + Parquet sebagai baseline tanpa indeks spasial. Ketiganya dimuat dari sampel yang sama dan diukur oleh satu harness. Citra asli tidak ikut dimuat; katalog hanya menyimpan penunjuk ke Zenodo.



arsitektur · 1 sumber, 3 penyimpanan, 1 harness uji

Kotak beraksen menandai dua penyimpanan yang punya indeks spasial; HDFS + Parquet tidak punya. Garis putus-putus antara metadata dan citra adalah penunjuk, bukan alur muat. Garis putus-putus ke bawah menandai titik ukur dari sisi server.

Alur data

1. **Muat awal.** Python memprofil `sen12tp-metadata.json` dan membuat sampel S1, S10, S100, S1000 dengan seed tetap. Sampel yang sama dikonversi dan dimuat ke MongoDB (NDJSON dengan `mongoimport`), PostgreSQL/PostGIS (CSV dengan WKT, lalu `COPY` dan `ST_GeomFromText`), dan HDFS (Parquet ZSTD dengan kolom bbox).
2. **Bangun indeks.** Setelah muat massal, indeks `2dsphere` dan indeks biasa dibangun di MongoDB, indeks GiST dan btree di PostGIS. Waktu bangun indeks dicatat (W7). Parquet tidak punya indeks spasial.
3. **Pencarian.** Klien menjalankan kueri W1 sampai W6: lookup per `scene_id`, titik-dalam-poligon, titik ditambah bulan, irisan area dengan filter tutupan lahan, dan agregasi. MongoDB memakai `$geoIntersects`, PostGIS memakai `ST_Intersects`, dan Spark SQL memfilter kolom bbox lalu, bila hasil harus eksak, menguji poligon pada baris kandidat saja.
4. **Penambahan scene baru.** Skrip menambahkan batch scene baru (ID baru dari generator) ke ketiganya: `insertMany` atau `mongoimport`, `COPY` atau `INSERT` batch, dan berkas Parquet baru per batch yang digabung berkala (W8).
5. **Pengujian.** Harness menjalankan W1–W10 pada ketiga penyimpanan dan mengumpulkan metrik dari klien serta dari server. Jumlah scene hasil W2 sampai W4 dibandingkan antar penyimpanan.

Ekstensi opsional: Apache Sedona atau GeoParquet di sisi Spark untuk menguji baseline yang punya fungsi spasial, dan tipe `geography` di PostGIS untuk menyamakan semantik bola dengan MongoDB.

Draf model data

Satu scene punya tiga bentuk: dokumen GeoJSON di MongoDB, baris bertipe dengan kolom geometri di PostGIS, dan baris datar dengan kolom bbox di berkas Parquet. Ketiganya berangkat dari atribut inti yang sama (lihat kamus data di bagian profil dataset).

Aspek	MongoDB	PostgreSQL/PostGIS	HDFS + Parquet
Satuan data	Dokumen BSON per scene	Baris pada tabel `scenes`	Baris datar dalam berkas Parquet kolumnar
Kunci	`_id` = `scene_id`	`PRIMARY KEY (scene_id)`	Tidak ada; partisi opsional
Geometri	Objek GeoJSON Polygon di `geometry`	`geometry(Polygon, 4326)` di `geom`	WKT atau WKB, ditambah kolom bbox (`min_lon`, `max_lon`, `min_lat`, `max_lat`)
Waktu	`Date` (UTC): `s1_time`, `s2_time`	`timestamptz`: `s1_time`, `s2_time`	`timestamp` (UTC): `s1_time`, `s2_time`
Indeks	`2dsphere` pada `geometry`; compound {landcover,	GiST pada `geom`; btree (landcover, month),	Statistik min/maks per row group; tidak ada

Aspek	MongoDB	PostgreSQL/PostGIS	HDFS + Parquet
	month}; s2_time; spatial_id	s2_time, spatial_id	indeks spasial
Penambahan	insertMany atau mongoimport	COPY atau INSERT batch	Berkas Parquet baru per batch, kompaksi berkala

MongoDB

Contoh dokumen dari scene pertama di berkas (scene 1868), dengan nilai asli dari berkas. Format Extended JSON untuk mongoimport: tanggal ditulis dengan $date, dan koordinat berurutan bujur lalu lintang.

```
{
  "_id": 1868,
  "spatial_id": 720,
  "split": "train",
  "climate": "Cs - Temperate, dry summer",
  "landcover": "Ice/Snow",
  "s1_time": { "$date": "2019-12-27T23:27:55Z" },
  "s2_time": { "$date": "2019-12-27T14:42:32.727Z" },
  "utm_epsg": "EPSG:32719",
  "month": 12,
  "geometry": {
    "type": "Polygon",
    "coordinates": [[
      [-70.41461164636456, -34.46821038082358],
      [-70.41766941105496, -34.648607215731495],
      [-70.19936915608972, -34.6509501024817],
      [-70.19678194300914, -34.47053762151857],
      [-70.41461164636456, -34.46821038082358]
    ]]
  }
}
```

Indeks:

- { geometry: "2dsphere" }: titik-dalam-poligon dan irisan area (W2 sampai W4). Dokumentasi MongoDB menyebut indeks 2dsphere mendukung kueri pada permukaan bola, dan $geoIntersects memakai geometri bola.
- { landcover: 1, month: 1 }: filter atribut dan agregasi (W4, W5, W6).
- { s2_time: 1 }: rentang waktu (W3).
- { spatial_id: 1 }: semua scene dari satu area kajian.
- $geoIntersects tidak mewajibkan indeks geospasial, tetapi indeks mempercepat kueri menurut dokumentasi. Eksperimen E1 menjalankannya dengan dan tanpa indeks.
- Muat massal: jangan pakai --jsonArray untuk S100 dan S1000, karena opsi itu dibatasi 16 MB menurut dokumentasi mongoimport. Tulis satu dokumen per baris (NDJSON).

PostgreSQL/PostGIS

```
CREATE EXTENSION IF NOT EXISTS postgis;
```

```
CREATE TABLE scenes (
  scene_id integer PRIMARY KEY,
  spatial_id integer NOT NULL,
  split text NOT NULL,
  climate text NOT NULL,
  landcover text NOT NULL,
  s1_time timestamptz NOT NULL,
  s2_time timestamptz NOT NULL,
  utm_epsg text NOT NULL,
  month smallint NOT NULL,
  geom geometry(Polygon, 4326) NOT NULL
);

CREATE INDEX scenes_geom_gist ON scenes USING gist (geom);
CREATE INDEX scenes_landcover_month ON scenes (landcover, month);
CREATE INDEX scenes_spatial_id ON scenes (spatial_id);
CREATE INDEX scenes_s2_time ON scenes (s2_time);
```

- `NOT NULL` dipakai karena profiling tidak menemukan nilai kosong.
- Tipe `geometry` bersifat planar: derajat bujur–lintang dianggap bidang datar. Indeks 2dsphere MongoDB memakai bola. Selisih hasil di tepi poligon diuji silang; tipe `geography` (bola) menjadi eksperimen opsional, dengan catatan fungsinya lebih sedikit dan lebih berat bagi CPU menurut dokumentasi PostGIS.
- Indeks GiST hanya menyimpan bounding box. Planner memakainya sebagai filter awal, lalu predikat spasial memastikan kecocokan. Bila planner tidak memakai indeks, jalankan `EXPLAIN` dan `VACUUM ANALYZE` (saran dokumentasi PostGIS).
- Muat: CSV dengan kolom `wkt` dimasukkan ke tabel sementara lewat `COPY`, lalu `INSERT ... SELECT` dengan `ST_GeomFromText(wkt, 4326)`. Bangun indeks setelah muat massal.
- E1: bandingkan W2 sampai W4 dengan dan tanpa indeks GiST.

HDFS + Parquet

```
/data/sen12tp/raw/sen12tp-metadata.json  salinan asli, tidak diubah
/data/sen12tp/parquet/s1/                sampel 1×
/data/sen12tp/parquet/s10/               sampel 10×
/data/sen12tp/parquet/s100/              sampel 100×
/data/sen12tp/parquet/s1000/             sampel 1.000×
/data/sen12tp/append/batch=0001/         batch scene baru (W8)
```

- Kolom: atribut datar yang sama, `s1_time` dan `s2_time` bertipe timestamp, `geom_wkt`, dan bbox `min_lon`, `max_lon`, `min_lat`, `max_lat`. Kompresi ZSTD lewat opsi `compression` di Spark.
- Tanpa indeks spasial: pencarian titik berarti memindai dengan pra-filter bbox. Statistik min/maks per row group baru membantu bila berkas diurutkan menurut lokasi. Eksperimen opsional E3 membandingkan Parquet acak dengan yang diurutkan menurut `min_lat` dan `min_lon`.
- Replikasi blok 2 (dua DataNode). Pada S1 berkasnya hanya sekitar 1 MB, jauh di bawah satu blok HDFS; kemungkinan hanya S1000 yang melampaui satu blok (perkiraan, ukur setelah konversi). Karena itu baseline paling bermakna pada S1000.
- Penambahan scene: berkas baru per batch di `append/`, lalu kompaksi berkala agar tidak menumpuk berkas kecil.

Satu kueri, tiga penyimpanan

Contoh W3: scene yang menutupi satu titik pada bulan Desember. Titik (−70,30; −34,55) berada di dalam poligon scene 1868 (bulan 12), jadi hasilnya minimal berisi scene itu. Ini draf yang belum dijalankan;

perbaiki saat implementasi di Tugas Tengah Semester. Contoh di dokumentasi `$geoIntersects` memakai Polygon, sedangkan bentuk dengan Point di bawah mengikuti sintaks yang sama dan perlu diuji.

```
// MongoDB
db.scenes.find(
  { month: 12,
    geometry: { $geoIntersects: { $geometry: { type: "Point", coordinates: [-70.30, -34.55] } } } },
  { landcover: 1, s2_time: 1 }
)
```

```
-- PostgreSQL/PostGIS
SELECT scene_id, landcover, s2_time
FROM scenes
WHERE month = 12
  AND ST_Intersects(geom, ST_SetSRID(ST_MakePoint(-70.30, -34.55), 4326));
```

```
-- Spark SQL (view scenes di atas berkas Parquet): pra-filter bbox
SELECT scene_id, landcover, s2_time
FROM scenes
WHERE month = 12
  AND min_lon <= -70.30 AND max_lon >= -70.30
  AND min_lat <= -34.55 AND max_lat >= -34.55;
-- Hasil ini adalah kandidat, karena bbox lebih longgar daripada poligon.
-- Untuk hasil eksak, uji titik-dalam-poligon dengan UDF pada baris kandidat saja.
```

Jumlah scene dari ketiganya dibandingkan. Selisih tipis di tepi poligon dicatat, bukan dianggap galat.

Rencana pengujian

Rencana ini membandingkan MongoDB, PostgreSQL/PostGIS, dan Spark SQL di atas HDFS + Parquet pada sepuluh beban kerja (W1–W10) di skala 1×, 10×, 100×, dan 1.000×, lalu menguji empat hipotesis. Skala uji utama adalah S1000, karena S100 hanya ± 232 ribu record. Pelaksanaannya di Tugas Tengah Semester; di sini baru rancangannya.

Beban kerja

Kode	Beban kerja	Diuji pada	Metrik
W1	Cari satu scene per `scene_id`; konkurensi 1, 10, 50, 100	MongoDB, PostGIS, Spark SQL (satu klien)	p50, p95, p99, QPS, error
W2	Scene yang menutupi satu titik (titik-dalam-poligon), 100 titik tetap	Ketiganya	p50, p95, jumlah hasil
W3	Scene yang menutupi satu titik pada satu bulan (spasial-temporal)	Ketiganya	p50, p95, jumlah hasil
W4	Scene yang beririsan dengan kotak area	Ketiganya	p50, p95, jumlah hasil

Kode	Beban kerja	Diuji pada	Metrik
	(kecil dan besar), difilter `landcover` (kelas jarang dan umum)		
W5	Jumlah scene per `landcover`, dan per `climate` × `landcover`	Ketiganya	Waktu kueri
W6	Jumlah scene per bulan dan `climate`	Ketiganya	Waktu kueri
W7	Muat massal S1, S10, S100, S1000, bangun indeks, dan ukuran penyimpanan	Ketiganya	Waktu muat, waktu bangun indeks, GB di disk
W8	Tambah satu batch scene baru (inkremental)	Ketiganya	Waktu tambah, record per detik
W9	Beban campuran: 90% baca (W1, W2, W3) dan 10% tulis, 5 menit, konkurensi 50	MongoDB, PostGIS	p95 baca saat ada penulisan
W10	Uji kegagalan: matikan primary MongoDB, satu DataNode HDFS, dan (opsional) promosikan standby PostgreSQL	Masing-masing	Waktu pulih, error, data hilang

Parameter W9 dan W10 adalah titik awal dan boleh disesuaikan. Titik uji W2 dan W3 diambil dengan seed tetap: sebagian dari dalam poligon yang ada (pasti ada hasil) dan sebagian dari luar (hasil kosong).

Eksperimen tambahan:

- E1: ulangi W2 sampai W4 dengan dan tanpa indeks spasial (2dsphere di MongoDB, GiST di PostGIS).
- E2: kurva skala, ulangi W1 sampai W6 di S1, S10, S100, dan S1000.
- E3 (opsional): Parquet acak versus diurutkan menurut lokasi.
- E4 (opsional): PostGIS `geography` versus `geometry`.

Pada skala kecil, waktu mulai job Spark mendominasi. Ukur di sesi yang sudah hangat dan, bila perlu, tambahkan pembanding yang membaca Parquet yang sama dengan mesin kueri berkas lain (misalnya DuckDB) agar efek layout terpisah dari overhead Spark.

Rancangan percobaan

- Skala: S1, S10, S100, dan S1000. Tiap pengukuran diulang minimal 3 kali; laporkan median dan rentangnya.
- Cold dan warm: cold = sesaat setelah container dinyalakan ulang; warm = setelah satu kali pemanasan.
- Adil: sampel dan seed sama untuk ketiga penyimpanan. W1 sampai W4 memakai daftar tetap ID dan titik. Memori tiap container dibatasi, misalnya `--wiredTigerCacheSizeGB` pada MongoDB dan `shared_buffers` pada PostgreSQL.
- Terisolasi: satu penyimpanan aktif pada satu waktu supaya sumber daya laptop tidak saling mengganggu. Alat beban berbagi CPU yang sama dengan database (prosesor laptop kemungkinan dual-core), jadi pengujian yang dibandingkan dijalankan di mesin yang sama.
- Tercatat: versi perangkat lunak, spesifikasi laptop, dan konfigurasi tiap layanan.
- Uji silang: jumlah scene hasil W2 sampai W4 dibandingkan antar penyimpanan; selisih MongoDB (bola) dan PostGIS (planar) di tepi poligon dicatat.

Alat dan titik ukur

- Klien beban dan latensi (W1 sampai W4, W9): skrip Python dengan `pymongo` dan `psycopg` dan pencatat waktu yang sama untuk ketiganya. Locust bisa dipakai untuk konkurensi (perilaku pengguna ditulis dalam Python), tetapi halaman utamanya hanya memberi contoh HTTP, jadi MongoDB dan PostgreSQL butuh klien kustom.
- `explain("executionStats")` dan `mongostat` di MongoDB.
- `EXPLAIN (ANALYZE, BUFFERS)` di PostgreSQL; `pgbench` dengan skrip SQL kustom (`-f`) dan banyak klien (`-c`) sebagai alternatif untuk beban SQL.
- Spark UI untuk waktu tiap stage dan byte yang dibaca.
- `docker stats` untuk CPU dan RAM; `collStats`, `pg_total_relation_size`, dan `hdfs dfs -du` untuk ukuran.
- Titik ukur ini digambar di diagram arsitektur.

Hipotesis (dugaan awal, belum diuji)

Kode	Hipotesis	Diuji lewat	Ditolak bila
H1	Dengan indeks spasial, MongoDB dan PostGIS lebih cepat daripada baseline Parquet pada W2 dan W3, dan selisihnya melebar dari S100 ke S1000	W2, W3, E1, E2	Selisih mengecil atau terbalik
H2	Pada kueri gabungan spasial dan atribut (W4), PostGIS lebih cepat daripada MongoDB, dengan dugaan planner relasional bisa memadukan indeks spasial dan indeks	W4	MongoDB sama cepat atau lebih cepat

Kode	Hipotesis	Diuji lewat	Ditolak bila
	atribut		
H3	Ukuran di disk dari kecil ke besar: Parquet (ZSTD), PostGIS, MongoDB (termasuk indeks)	W7	Urutannya berbeda
H4	Setelah primary MongoDB mati, penulisan pulih dalam median ≤ 12 detik tanpa kehilangan tulis majority; HDFS tetap melayani baca saat satu DataNode mati	W10	Median lebih dari 12 detik, ada tulis yang hilang, atau baca gagal

Angka 12 detik berasal dari dokumentasi MongoDB untuk konfigurasi default; hasil ukur kita yang menentukan. H2 dan H3 paling spekulatif, jadi jangan ditulis sebagai klaim di Sheet sebelum diuji.

Template hasil

Salin baris untuk tiap beban kerja dan skala, lalu isi saat Tugas Tengah Semester. Nilai adalah median dari minimal 3 ulangan; W1 sampai W4 juga melaporkan p95.

Beban kerja	Skala	MongoDB	PostGIS	Spark SQL
W1 (konkurensi 50)	S1000			
W3	S1000			
W5	S1000			
W7 (waktu muat dan ukuran)	S1000			

Link siap pakai

Tautan dikelompokkan menurut kebutuhan. "Dibuka" berarti halamannya saya buka pada 10 Okt 2026; "Dibuka (9 Okt)" berarti saya membukanya di sesi sebelumnya. "Diunduh" berarti sudah diunduh dan dicek oleh Wildan. "Belum dibuka" berarti alamatnya berasal dari halaman lain, daftar dosen, atau pola alamat yang sama, dan tidak bisa saya uji dari lingkungan kerja saya, jadi klik dulu sebelum dikutip di laporan.

Dataset utama: SEN12TP

Kebutuhan	Tautan	Status

Kebutuhan	Tautan	Status
Halaman dataset, daftar berkas, lisensi, deskripsi	Zenodo: SEN12TP	Dibuka
Unduh berkas metadata (1,3 MB)	sen12tp-metadata.json	Diunduh, MD5 cocok
Daftar MD5 semua berkas (596,2 kB)	md5sums.txt	Belum dibuka (pola alamat sama dengan berkas metadata)
DOI dataset	10.5281/zenodo.7342060	Belum dibuka
Makalah terkait (judul dari halaman Zenodo)	doi 10.1007/s41064-023-00238-y	Belum dibuka (hanya dialihkan ke Springer)
Entri di Lampiran Dataset dosen	"Sen12Landslides & SEN12TP": TerraMosaic Hub dan Zenodo SEN12TP di atas	Dibuka; halaman TerraMosaic hanya memuat Sen12Landslides, tidak ada entri SEN12TP
Konteks masalah: standar katalog citra	STAC: About	Dibuka

Dokumentasi teknologi

Teknologi	Topik	Tautan	Status
MongoDB	Indeks 2dsphere (geometri bola, urutan bujur–lintang)	2dsphere	Dibuka
MongoDB	Operator `$geoIntersects`	$geoIntersects	Dibuka
MongoDB	Batas dokumen 16 MiB dan GridFS	Limits	Dibuka
MongoDB	Replikasi dan pemilihan primary (sumber angka ± 12 detik)	Replication	Dibuka (9 Okt)
MongoDB	Impor data (NDJSON, batas `--jsonArray` 16 MB)	mongoimport	Dibuka
MongoDB	Image Docker	mongo	Dibuka
MongoDB	Pemantauan, write concern, pemodelan data	mongostat, Write concern, Data modeling	Belum dibuka
PostGIS	ST_Intersects dan pemakaian indeks	ST_Intersects	Dibuka

Teknologi	Topik	Tautan	Status
	spasial otomatis		
PostGIS	Indeks GiST, geometry versus geography	Manajemen data PostGIS	Dibuka
PostGIS	Image Docker (tag yang disarankan di halamannya: 18-3.6 dan 17-3.5)	postgis/postgis	Dibuka
PostgreSQL	Replikasi streaming (asinkron secara default), promosi standby	Warm standby	Dibuka
PostgreSQL	Muat massal CSV	COPY	Dibuka
HDFS	Desain HDFS: tulis-sekali-baca-banyak, NameNode, DataNode	HDFS Design	Dibuka
HDFS	Image Docker	apache/hadoop	Dibuka (9 Okt)
Parquet dan Spark	Membaca Parquet, kompresi, partisi	Spark: Parquet	Dibuka
Spark	Image Docker	apache/spark	Dibuka
Parquet	Format Parquet	Apache Parquet	Belum dibuka
Opsional	Fungsi spasial di Spark dan geometri di Parquet	Apache Sedona, GeoParquet	Dibuka
DuckDB	Pembanding pembacaan Parquet	DuckDB docs	Belum dibuka

Alat uji dan gambar

Alat	Dipakai untuk	Tautan	Status
Locust	Beban dan persentil latensi; perilaku pengguna ditulis dalam Python, sedangkan halaman utamanya hanya memberi contoh HTTP	locust.io	Dibuka
pgbench	Beban SQL kustom (-f) dengan banyak klien (-	pgbench	Dibuka

Alat	Dipakai untuk	Tautan	Status
	c) di PostgreSQL		
draw.io	Diagram arsitektur final	app.diagrams.net	Belum dibuka

Opsi cadangan

Opsi	Tautan	Status
Open Food Facts + MongoDB + ClickHouse (dokumen kelompok sebelumnya)	Dokumen Open Food Facts; data: Open Food Facts	Dibuka (9 Okt)

Draf pesan ke dosen

SEN12TP tercantum di Lampiran Dataset, jadi pesan ini bukan permintaan persetujuan dataset. Isinya konfirmasi singkat bahwa kelompok hanya memakai berkas metadata dan bagian SEN12TP dari entri "Sen12Landslides & SEN12TP". Kirim setelah kombinasi terdaftar di Sheet, dan sesuaikan sapaan serta kanalnya (LMS, email, atau WhatsApp). Isi bagian dalam [kurung siku].

Yth. Bapak/Ibu [nama dosen],

Kami dari KELOMPOK 2, kelas [kelas], memilih dataset SEN12TP dari Lampiran Dataset Tugas 2 (Perancangan Konsep Arsitektur Penyimpanan dan Pemilihan Data). Kombinasi teknologi dan dataset ini sudah kami daftarkan di Google Sheet.

Judul yang kami daftarkan: Perbandingan MongoDB dan PostgreSQL/PostGIS terhadap Baseline HDFS-Parquet sebagai Penyimpanan Katalog Metadata Citra Satelit Sentinel-1/2 SEN12TP untuk Pencarian Spasial-Temporal Data Penginderaan Jauh.

Dataset: SEN12TP - Sentinel-1 and -2 images, timely paired (Roßberg & Schmitt, 2023; lisensi CC BY 4.0), https://zenodo.org/records/7342060. Entri di lampiran memuat dua dataset (Sen12Landslides dan SEN12TP); kami memakai SEN12TP lewat tautan Zenodo tersebut. Dari SEN12TP kami hanya memakai berkas metadata sen12tp-metadata.json (1,3 MB), bukan citranya (± 222 GB). Berkas itu berformat GeoJSON (semi-terstruktur), berisi 2.319 scene dengan 9 atribut dan geometri poligon.

Skala: 1× adalah 2.319 scene asli. Skala 100× (± 232 ribu record) dan 1.000× (± 2,3 juta record) kami buat lewat simulasi dari sebaran data asli.

Teknologi: MongoDB (document store) dan PostgreSQL/PostGIS (relasional), dengan HDFS + Parquet sebagai baseline pembanding.

Mohon konfirmasi bahwa pemakaian berkas metadata saja dan definisi 1× di atas dapat diterima. Terima kasih atas perhatian dan arahan Bapak/Ibu.

Hormat kami,

[nama pengirim, NIM], mewakili KELOMPOK 2

Asumsi dan yang perlu dikonfirmasi

Sembilan hal di bawah menentukan apakah rancangan ini bisa dipakai apa adanya; tiga yang pertama bergantung pada dosen, SIDIA, atau Sheet.

Perlu dikonfirmasi

- ☐ Dosen menerima pemakaian berkas metadata saja dan bagian SEN12TP dari entri "Sen12Landslides & SEN12TP", beserta definisi 1× = 2.319 scene (Anggota 1).
- ☐ Batas pengumpulan di SIDIA; jadwal 6 hari di atas menyesuaikan (Anggota 1).
- ☐ Cek Sheet dosen: belum ada kelompok lain dengan kombinasi yang sama. Baris Kelompok 3 dan 5 belum terlihat terisi di tangkapan layar 9 Okt 12.41, jadi cek lagi (Anggota 1).
- ☐ Kelas dan nama kelompok untuk pesan ke dosen (Anggota 1).
- ☐ Istilah kategori penyimpanan selaras dengan hasil Tugas 1 kelompok, yang belum saya lihat (Anggota 1, 3, 4).
- ☐ Generator skala menghasilkan S10, S100, dan S1000 sesuai rencana, dan ukuran berkas serta Parquet diukur (Anggota 2).
- ☐ Nama dan tipe kolom di draf model data cocok dengan hasil profiling dan keluaran generator (Anggota 2, 3, 4).
- ☐ Jumlah scene hasil W2 sampai W4 dibandingkan antar penyimpanan, dan selisih MongoDB (bola) dengan PostGIS (planar) dicatat (Anggota 5).
- ☐ RAM dan disk semua laptop dicek, lalu diputuskan apakah standby PostgreSQL dan replica set 3 node MongoDB dijalankan (semua anggota).

Asumsi yang saya buat

- Baseline HDFS + Parquet dihitung di luar "minimal 2 teknologi dari kategori berbeda". Bila dosen menghitungnya di dalam, rancangan tetap memenuhi syarat selama kategori di Tugas 1 memisahkan MongoDB (document store) dan PostgreSQL/PostGIS (relasional).
- SEN12TP di lampiran dianggap boleh dipakai tanpa persetujuan dataset. Konfirmasi tentang pemakaian metadata saja tetap disarankan.
- Enam peran di soal digabung menjadi lima (Project Lead + Documentation/QA); boleh ditukar sesuai kekuatan anggota.
- Angka dataset (2.319 scene, 1.236 area, sebaran nilai) berasal dari profiling berkas yang diunduh pada 10 Okt 2026. Angka 222 GB (tanpa kompresi) dan 237,9 GB (zip) berasal dari halaman Zenodo; ukuran ± 96 MB per scene adalah hitungan saya (222 GB dibagi 2.319).
- Skala 100× dan 1.000× adalah hasil simulasi, bukan data nyata. Ukuran berkas mentahnya perkiraan dari ± 545 byte per feature.
- Perkiraan jam kerja, penilaian Kuat/Sedang/Lemah, dan kebutuhan RAM serta disk adalah tebakan saya, bukan hasil pengukuran.
- DDL, kueri, dan pola muat di draf model data belum dijalankan. Bentuk `$geoIntersects` dengan Point mengikuti sintaks di dokumentasi tetapi belum diuji.
- Hipotesis H1 sampai H4 adalah dugaan desain, dan posisi CAP ditulis dengan kata "condong" atau "menurut penilaian kami".
- Jadwal 6 hari mengasumsikan batas pengumpulan Kamis 15 Okt 2026.
- Kode iklim di berkas tampaknya mengikuti klasifikasi Köppen–Geiger. Makalahnya belum bisa saya buka, jadi cek sebelum ditulis di laporan.