Panduan Kerja KELOMPOK 2

Tugas 2 Big Data Storage · SEN12TP: MongoDB + PostgreSQL/PostGIS vs HDFS–Parquet

Versi 1 · 17 Okt 2026 · Project Lead: Wildan

Intinya (baca ini dulu)

1. Kabar dan diskusi lewat **grup WhatsApp**. Kode, kueri, dan hasil uji lewat **satu repo GitHub privat**.
2. **Satu orang, satu folder.** Ubah hanya folder perannya sendiri.
3. **Hari ini:** kirim username GitHub ke Wildan, lalu kerjakan Langkah awal (bagian 3), sekitar 1–2 jam.
4. Selesai mengerjakan sesuatu yang ditunggu orang lain? Tulis **[SELESAI]** di grup. Macet lebih dari 1 jam? Tulis **[BLOKIR]**.
5. **Kecil dulu, baru besar.** Semuanya harus berjalan benar di S1 (data asli, 2.319 scene) sebelum naik ke S100 dan S1000.

1 Pembagian peran

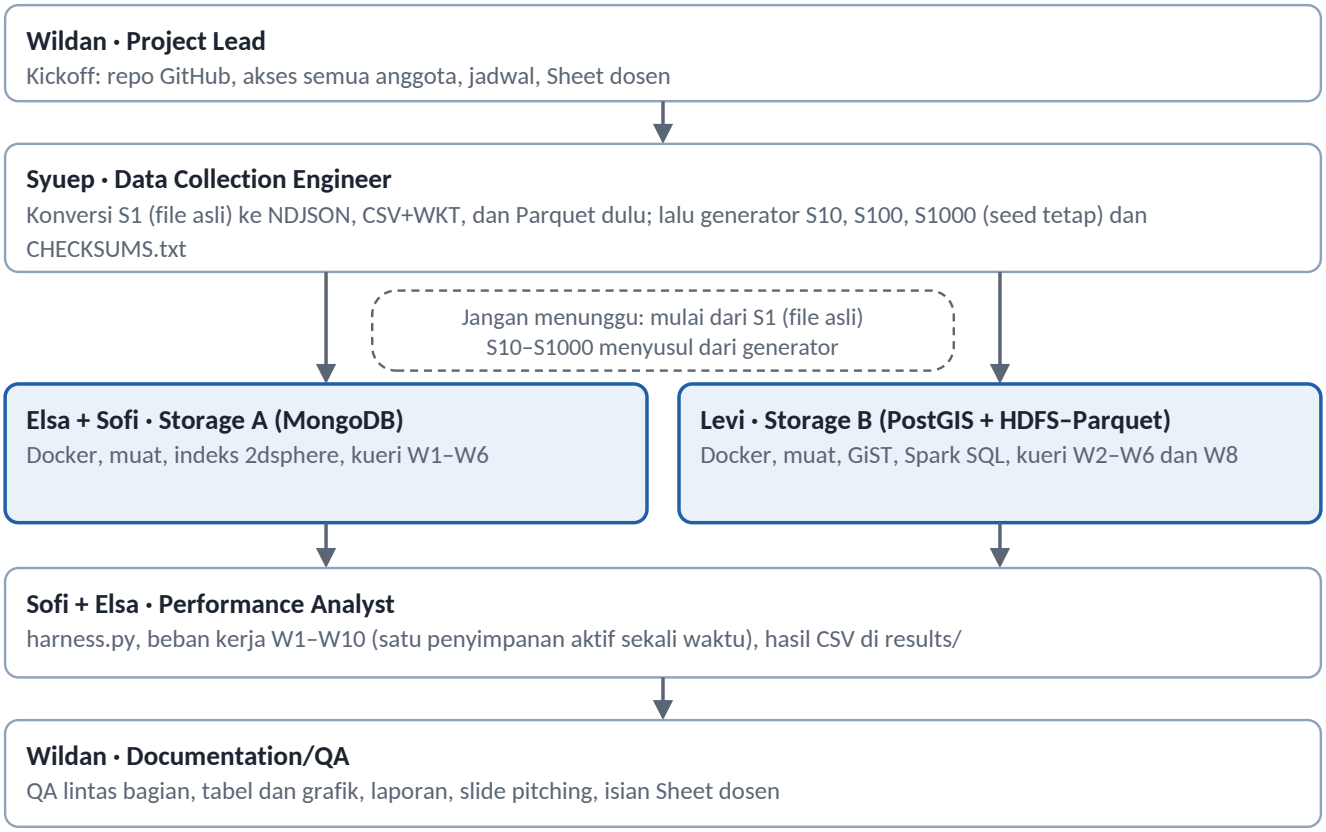
Peran	PIC	Tugas utama	Folder repo
Project Lead + Documentation/QA	**Wildan**	Koordinasi dan jadwal, isian Sheet, diagram arsitektur final, QA lintas bagian, slide pitching, laporan	`docs/`
Data Collection Engineer	**Syuep**	Konversi S1, generator S10–S1000 (seed tetap), kamus data, CHECKSUMS.txt	`data/`
Storage Engineer A (MongoDB)	**Elsa**, Sofi	Docker MongoDB (replica set), skema dan indeks 2dsphere, muat massal, kueri W1–W6	`mongodb/`
Storage Engineer B (PostgreSQL/PostGIS + baseline HDFS–Parquet)	**Levi**	DDL PostGIS dan indeks GiST, muat dengan COPY, HDFS + Spark, Spark SQL, kueri W2–W6 dan W8	`postgis/` `hdfs-parquet/`
Performance Analyst	**Sofi**, Elsa	Harness uji (Python), beban kerja W1–W10, tabel dan grafik hasil, uji silang jumlah hasil	`bench/` `results/`

- **Dua orang pada satu peran:** nama pertama memimpin, yang kedua membantu dan meninjau (usulan, boleh ditukar). Elsa dan Sofi memegang dua peran sekaligus, jadi bagi per berkas agar tidak saling menimpa.
- **Beban Levi paling berat:** dua penyimpanan, dan HDFS + Spark paling banyak memakan memori. Usulan: begitu konversi dan generator selesai, Syuep membantu bagian HDFS–Parquet (konversi Parquet dan draf Spark SQL).
- **Tinjau silang:** Elsa/Sofi dan Levi saling memeriksa justifikasi dan kueri; Syuep dan Sofi/Elsa saling memeriksa profil data dan rencana uji; Wildan menutup dengan QA. Bila berbeda pendapat, Project Lead memutuskan.
- Rincian tugas tiap peran ada di dokumen rancangan, bagian Pembagian tugas (Anggota 1 = Wildan, 2 = Syuep, 3 = Elsa/Sofi, 4 = Levi, 5 = Sofi/Elsa).

Istilah: W1–W10 = daftar beban kerja uji di dokumen rancangan; W3 = scene yang menutupi satu titik pada bulan tertentu (contoh kueri ada di dokumen, bagian Draf model data). S1 = data asli (2.319 scene); S10, S100, S1000 = hasil simulasi 10×, 100×, dan 1.000×.

2 Alur kerja

Pekerjaan mengalir dari atas ke bawah; kotak yang sejajar dikerjakan bersamaan. Panah berarti serah terima: pengirim menulis **[SELESAI]** di grup supaya penerima bisa mulai.



Kotak biru: dua penyimpanan berindeks spasial. HDFS + Parquet (baseline, tanpa indeks spasial) ikut di kotak Levi.

3 Langkah awal (Hari 1)

Urutannya: persiapan, kickoff, lalu tugas pertama tiap peran. Sekitar 1–2 jam per orang.

Wildan, sebelum kickoff (± 45 menit)

- Buat repo GitHub privat `kelompok2-bigdata-storage` dengan kerangka folder di bagian 6, lalu undang empat anggota lewat Settings → Collaborators → Add people (butuh username GitHub mereka).
- Taruh `sen12tp-metadata.json` dan `profil.py` (sudah diunduh dan diprofil) di `data/raw/`.
- Pin di grup: PDF ini, tautan dokumen rancangan, tautan Sheet dosen, dan batas kumpul dari SIDIA.
- Cek Sheet dosen: belum ada kelompok lain dengan kombinasi yang sama. Daftarkan bila belum, lalu kirim pesan konfirmasi ke dosen.

Semua anggota (± 1,5 jam, termasuk kickoff)

- Kirim username GitHub ke Wildan, lalu terima undangan repo.
- Pasang Git (atau GitHub Desktop), Python 3.11 atau lebih baru, dan Docker Desktop. Di Windows, Docker Desktop memakai WSL2; bila RAM laptop 12 GB atau kurang, batasi memorinya lewat `.wslconfig` (misalnya `memory=6GB`).
- Uji alur Git: `git clone` repo, tambahkan baris namamu di `TEAM.md`, commit, lalu push.
- Tulis di grup: RAM, ruang disk kosong, dan prosesor laptopmu.
- **Kickoff 30 menit** lewat panggilan grup: cocokkan peran dan usulan di bagian 1; tetapkan batas kumpul, jadwal pitching, jam Sinkron 1 dan 2, dan laptop untuk uji S1000 (perkiraan kebutuhan bila semua layanan jalan sekaligus: ± 16 GB RAM dan ± 30 GB disk, belum diukur; bila kurang, jalankan satu penyimpanan sekali waktu).

Tugas pertama tiap peran

Siapa	Tugas pertama	Tanda selesai
Syuep	Skrip konversi S1 (file asli) ke NDJSON, CSV dengan WKT, dan Parquet dengan kolom bbox.	**[SELESAI]** S1 siap muat di `data/s1/`
Elsa, Sofi	Docker MongoDB, skema dan indeks (draf di dokumen), kueri W3; muat S1 begitu siap.	**[SELESAI]** W3 jalan di S1
Levi	Docker PostGIS, tabel scenes (DDL di dokumen), kueri W3; muat S1 begitu siap.	**[SELESAI]** W3 jalan di S1
Sofi, Elsa	Kerangka `harness.py`: waktu satu kueri, 3 ulangan, hasil ke CSV; tetapkan kolom CSV (bagian 6).	**[SELESAI]** harness mengukur satu kueri
Wildan	Diagram arsitektur v1 di draw.io; isian Sheet bagian 1–2.	**[SELESAI]** diagram v1 di `docs/`

4 Urutan pengerjaan

Tahap 1: paket Tugas 2 (rancangan dan pitching), 6 hari

H1 = hari kickoff. Bila batas kumpul lebih dekat dari enam hari, rapatkan: Sinkron 1 di tengah, Sinkron 2 sehari sebelum kumpul.

Hari	Fokus	Siapa mengerjakan apa
H1	Persiapan	Semua: Langkah awal (bagian 3). Wildan: Sheet dosen dan pesan ke dosen. Syuep: konversi S1.
H2–H3	Rancangan bagian masing-masing	Syuep: generator S10–S1000. Wildan: diagram v1, lalu v2. Elsa/Sofi: skema, indeks, ingest MongoDB. Levi: DDL PostGIS, layout Parquet. Sofi/Elsa: draf rencana uji.
Akhir H3	**Sinkron 1**	30–45 menit. Tiap orang menunjukkan hasilnya; samakan istilah dan nama kolom.
H4	Justifikasi dan perakitan	Elsa/Sofi dan Levi: tulis justifikasi lalu saling meninjau. Wildan: rakit isian Sheet. Syuep dan Sofi/Elsa: profil dataset dan rencana uji final.
H5	**Sinkron 2**	30–45 menit. QA lintas bagian oleh semua; latihan pitching dipimpin Wildan.
H6	Kumpul	Cadangan waktu. Wildan mengumpulkan; yang lain memeriksa isi sel dan angka.

Tahap 2: implementasi dan uji (Tugas Tengah Semester)

1. Syuep menyerahkan S1 siap muat (NDJSON, CSV+WKT, Parquet), lalu S10, S100, S1000 dan CHECKSUMS.txt.
2. Elsa/Sofi dan Levi: Docker jalan, muat S1, bangun indeks, kueri W1–W6 berjalan dan hasilnya masuk akal di S1. Baru setelah itu muat S10, S100, lalu S1000.
3. Sofi/Elsa menjalankan W1–W10 pada tiap penyimpanan (satu penyimpanan aktif sekali waktu, minimal 3 ulangan) dan menyimpan CSV di `results/`.
4. Uji silang: jumlah scene W2–W4 dibandingkan antar penyimpanan; selisih tipis di tepi poligon dicatat, bukan galat.
5. Wildan menyusun analisis, grafik, laporan, dan slide; semua meninjau.

5 Memberi kabar dan serah terima

- **Grup WhatsApp:** semua kabar dan tanya-jawab; pesan penting di-pin. GitHub: kode dan hasil.
- **Panggilan grup** (Meet atau WhatsApp): dua sinkron; Wildan kirim jadwalnya sehari sebelumnya.
- **Check-in tiap malam,** tiga baris dan boleh singkat: “Hari ini: … / Besok: … / Kendala: …”.

Tanda	Dipakai bila	Contoh pesan
[SELESAI]	Hasil siap dipakai orang lain	[SELESAI] data/: S1 siap muat di repo. @Elsa @Sofi @Levi silakan muat.
[BLOKIR]	Macet lebih dari 1 jam	[BLOKIR] mongoimport menolak geometri; urutan koordinat sudah dicoba. @Syuep tolong cek berkas S1.
[KEPUTUSAN]	Hal yang sudah disepakati	[KEPUTUSAN] Uji S1000 di laptop Levi, satu penyimpanan sekali waktu.

- Balas pesan yang menyebut namamu dalam 24 jam; cukup “oke, dilihat”. Wildan merangkum semua [KEPUTUSAN] di pesan yang di-pin.

6 Mengumpulkan hasil kerja: pakai GitHub

Jawaban singkat: ya, pakai GitHub (repo privat) untuk semua yang berupa teks: kode, kueri, konfigurasi, dan hasil uji berukuran kecil. Alasannya: lima orang bisa bekerja bersamaan di folder berbeda tanpa saling menimpa; riwayatnya mencatat siapa mengerjakan apa; dan mudah diulang di laptop lain (clone, lalu jalankan).

Yang tidak masuk GitHub: data besar (S100, S1000, Parquet), karena GitHub menolak berkas di atas 100 MB (buat ulang dari generator dan seed, lalu cocokkan dengan CHECKSUMS.txt), serta password dan berkas `.env`. Slide dan laporan final, juga berkas besar yang tidak bisa dibuat ulang, taruh di folder Google Drive kelompok.

Struktur repo

```
kelompok2-bigdata-storage/
├─ README.md        status dan cara menjalankan                 (Wildan)
├─ TEAM.md          nama, NIM, peran, username GitHub           (semua)
├─ .gitignore       data/out/, .env, __pycache__/
├─ data/            raw/ asli · s1/ siap muat · out/ S10–S1000 (tidak di-commit) (Syuep)
├─ mongodb/         compose, indeks, muat, kueri W1–W6          (Elsa, Sofi)
├─ postgis/         schema.sql, muat, kueri W2–W6 dan W8        (Levi)
├─ hdfs-parquet/    compose HDFS + Spark, Spark SQL             (Levi, Syuep)
├─ bench/           harness.py, daftar beban kerja W1–W10       (Sofi, Elsa)
├─ results/         CSV hasil uji dan grafik                    (Sofi, Elsa)
└─ docs/            diagram, laporan, slide                     (Wildan)
```

Cara kerja Git sehari-hari

```
git pull --rebase               # mulai kerja: ambil perubahan terbaru
git add mongodb/                # selesai: tambahkan folder sendiri
git commit -m "[mongodb] tambah indeks 2dsphere"
git pull --rebase               # ambil lagi bila ada yang baru
git push
```

- Awali pesan commit dengan nama folder. Dua orang di satu folder: bagi per berkas, atau kabari dulu sebelum mengubah berkas yang sama.
- Push ditolak? Jalankan `git pull --rebase`, lalu push lagi. Jangan memakai `--force`. Masih gagal: tulis [BLOKIR] di grup.
- Belum bisa Git? Pakai GitHub Desktop, atau kirim berkas ke Wildan lewat grup dan Wildan yang memasukkannya (tulis namamu di pesan commit).

Format hasil uji: satu CSV per percobaan di `results/`, misalnya `20261020_mongodb_W3_S1000.csv` (tanggal, penyimpanan, beban, skala). Kolom (usulan; Sofi dan Elsa menetapkannya di Hari 1): `penyimpanan, beban_kerja, skala, ulangan, cold_warm, waktu_ms, jumlah_hasil, catatan`.

Pengumpulan akhir ke dosen

- Hanya Wildan yang mengisi Sheet dosen, supaya sel kelompok lain tidak tertimpa. Klik dua kali sel tujuan sampai kursor ada di dalam sel, baru tempel; kalau tidak, teks pecah ke sel di bawahnya.
- Sesudah mengisi, Wildan kirim tangkapan layar ke grup; yang lain memeriksa isi sel (salah ketik dan angka). Diagram (PNG atau PDF) dan slide pitching ada di `docs/` atau folder Drive.